

Klasifikasi Sentimen, Toxicity, dan Emosi pada Teks Forum Menggunakan Model Machine Learning Berbasis Bahasa Indonesia

1st Matthew Yuslih
Department of Informatics
Universitas Multimedia Nusantara
Tangerang, Indonesia
matthew.yuslih@student.umn.ac.id

2nd Sebastian Obert
Department of Informatics
Universitas Multimedia Nusantara
Tangerang, Indonesia
sebastian.obert@student.umn.ac.id

3rd Manuel Manatap
Department of Informatics
Universitas Multimedia Nusantara
Tangerang, Indonesia
manuel.manatap@student.umn.ac.id

4th Jansen Caesar Tandiar
Department of Informatics
Universitas Multimedia Nusantara
Tangerang, Indonesia
jansen.caesar@student.umn.ac.id

5th Pierre Rambe
Department of Informatics
Universitas Multimedia Nusantara
Tangerang, Indonesia
pierre.rambe@student.umn.ac.id

Abstract—Perkembangan forum digital dan media sosial di Indonesia telah menghasilkan volume data teks yang sangat besar. Data ini mengandung informasi berharga mengenai opini publik, namun juga diiringi dengan konten negatif seperti ujaran kebencian (*hate speech*) dan toksisitas. Penelitian ini bertujuan untuk membangun model *machine learning* yang mampu melakukan klasifikasi multi-label pada teks forum berbahasa Indonesia, mencakup tiga aspek: sentimen (positif, negatif, netral), emosi (marah, senang, sedih, takut, cinta), dan toksisitas (*toxic* atau tidak). Dalam penelitian ini, dilakukan perbandingan antara dua algoritma populer, yaitu Naive Bayes sebagai model dasar dan Support Vector Machine (SVM) yang dioptimalkan melalui hyperparameter tuning menggunakan GridSearchCV. Proses penelitian meliputi tahap pra-pemrosesan data seperti pembersihan teks, penghapusan duplikat, dan stemming menggunakan Sastrawi, serta ekstraksi fitur menggunakan TF-IDF (5000 fitur). Hasil eksperimen menunjukkan bahwa model SVM secara konsisten mengungguli Naive Bayes. Setelah dilakukan tuning, SVM mencapai akurasi tertinggi pada dataset Toxicity sebesar 88.2% (kernel RBF), Sentimen sebesar 69.7% (kernel RBF), dan Emosi sebesar 61.7% (kernel Linear). Model ini diharapkan dapat menjadi alat yang efektif untuk moderasi konten dan analisis opini publik secara otomatis.

Keywords—*klasifikasi teks, sentimen, toxicity, emosi, machine learning, support vector machine, naive bayes, hyperparameter tuning.*

I. INTRODUCTION

Perkembangan teknologi informasi dan media sosial telah mengubah cara masyarakat Indonesia berinteraksi dan

mengekspresikan pendapat. Forum diskusi daring kini menjadi wadah utama bagi publik untuk merespons isu-isu krusial, mulai dari kebijakan politik hingga fenomena sosial. Volume data teks yang dihasilkan setiap harinya sangat besar, menciptakan peluang untuk memahami dinamika opini publik secara real-time. Namun, kebebasan berekspresi ini sering kali disertai dengan lonjakan konten negatif, termasuk ujaran kebencian (*hate speech*), kalimat ofensif (*abusive*), dan toksisitas yang dapat merusak ekosistem digital yang sehat [1],[2].

Urgensi dari permasalahan ini terlihat jelas pada studi kasus tagar "Indonesia Gelap" yang menjadi tren pada tahun 2025. Berdasarkan data awal yang dikumpulkan sebanyak 64.816 komentar, ditemukan bahwa sentimen publik sangat condong ke arah negatif, mencapai angka sekitar 81%, sementara hanya 8% yang bersifat positif dan 13% netral. Dominasi komentar negatif ini menghadirkan tantangan besar dalam moderasi konten. Metode moderasi manual tidak lagi efektif untuk menangani volume data sebesar ini, sehingga diperlukan pendekatan otomatis berbasis Machine Learning yang mampu mengklasifikasikan teks secara cepat dan akurat [3],[4].

Tantangan dalam analisis teks forum tidak hanya terbatas pada penentuan polaritas sentimen (positif, negatif, dan netral) tetapi juga mencakup pengenalan emosi spesifik (seperti marah, sedih, dan takut) dan deteksi tingkat toksitas. Namun, Naive Bayes memiliki keterbatasan asumsi

independensi antar fitur yang sering kali tidak berlaku pada data teks yang kompleks. Di sisi lain, Support Vector Machine (SVM) dikenal memiliki performa yang baik pada data berdimensi tinggi, namun kinerjanya sangat bergantung pada pemilihan hyperparameter yang tepat [5],[6].

Merespons tantangan tersebut, penelitian ini mengusulkan pengembangan model klasifikasi multi-label pada teks forum berbahasa Indonesia yang mencakup tiga tugas utama: analisis sentimen, klasifikasi emosi, dan deteksi toksisitas. Penelitian ini bertujuan untuk membandingkan kinerja algoritma Naive Bayes dan SVM, serta menerapkan teknik optimasi Hyperparameter Tuning menggunakan GridSearchCV untuk meningkatkan akurasi model SVM. Dengan memanfaatkan fitur Term Frequency-Inverse Document Frequency (TF-IDF) untuk merepresentasikan teks, penelitian ini diharapkan dapat menghasilkan model yang tidak hanya akurat dalam memetakan opini publik, tetapi juga efektif sebagai alat bantu moderasi konten otomatis di platform digital [9],[10].

II. RESEARCH METHODOLOGY LITERATURE REVIEW

Penggunaan *text mining* dan *natural language processing* (NLP) banyak diterapkan untuk menganalisis teks yang berasal dari internet, termasuk forum diskusi. Teks pada forum biasanya ditulis secara bebas oleh pengguna sehingga strukturnya tidak teratur dan sulit dianalisis secara langsung. Oleh karena itu, diperlukan proses awal seperti *tokenization*, *normalization*, dan pembentukan fitur agar teks dapat diubah menjadi bentuk numerik dan diproses oleh model *machine learning*. Christopher D. Manning, Prabhakar Raghavan, dan Hinrich Schütze menjelaskan bahwa konsep *information retrieval* menjadi dasar dalam pengolahan dokumen teks dan banyak digunakan dalam penelitian klasifikasi teks [1]. Salah satu metode yang masih sering digunakan dalam proses representasi teks adalah TF-IDF karena metode ini mampu menunjukkan kata-kata yang dianggap penting dalam sebuah dokumen [9].

Analisis sentimen merupakan salah satu pendekatan yang digunakan untuk mengetahui opini pengguna terhadap suatu

topik. Menurut Bing Liu, analisis sentimen bertujuan mengelompokkan teks ke dalam kategori positif, negatif, atau netral berdasarkan isi opini yang disampaikan [3]. Namun, dalam praktiknya, teks tidak selalu hanya berisi opini. Banyak teks yang juga mengandung unsur emosi penulisnya. Oleh sebab itu, analisis emosi menjadi penting untuk melengkapi analisis sentimen. Saif Mohammad menjelaskan bahwa emosi dalam teks dapat dikenali melalui kata-kata yang memiliki muatan afektif tertentu, sehingga emosi yang terkandung dalam teks dapat diidentifikasi [5].

Selain sentimen dan emosi, permasalahan toksisitas dan ujaran kebencian juga sering muncul dalam forum dan media sosial. Zafar Waseem dan Dirk Hovy menunjukkan bahwa pendekatan *machine learning* dapat digunakan untuk mendeteksi ujaran kebencian pada teks daring [2]. Penelitian tersebut sejalan dengan penelitian yang dilakukan oleh Fajri Alfina, Rinaldi Mulia, Muhammad Iqbal Fanany, dan Yudi Ekanata pada teks berbahasa Indonesia. Hasil penelitian tersebut menunjukkan bahwa klasifikasi teks dapat digunakan untuk mendeteksi ujaran kebencian, meskipun masih terdapat kendala seperti penggunaan bahasa tidak baku dan perbedaan konteks kalimat [4].

Dalam klasifikasi teks, beberapa algoritma *machine learning* telah banyak digunakan oleh peneliti. Andrew McCallum dan Kamal Nigam menjelaskan bahwa Naive Bayes merupakan algoritma yang sederhana dan efisien, namun tetap mampu memberikan hasil yang cukup baik dalam klasifikasi dokumen teks [6]. Selain itu, Support Vector Machine yang dikembangkan oleh Corinna Cortes dan Vladimir Vapnik juga sering digunakan karena mampu menangani data berdimensi tinggi seperti teks dan memberikan hasil klasifikasi yang stabil [8].

Pada tahap implementasi, proses pengujian model biasanya dibantu oleh pustaka pemrograman. Scikit-learn menyediakan berbagai algoritma *machine learning* serta alat evaluasi yang memudahkan proses eksperimen dan pengembangan model [10]. Untuk teks berbahasa Indonesia, proses *stemming* diperlukan agar kata dapat dikembalikan ke bentuk dasarnya, dan dalam penelitian ini digunakan

pustaka Sastrawi untuk mendukung proses tersebut [13]. Pemahaman mengenai konsep pembelajaran mesin mengacu pada teori yang dijelaskan oleh Christopher M. Bishop sebagai dasar dalam membangun model klasifikasi [14]. Penelitian terbaru oleh Lalu Muhammad Pratama menunjukkan bahwa analisis sentimen dan emosi pada teks berbahasa Indonesia masih memiliki keterbatasan, terutama karena sebagian penelitian hanya berfokus pada satu aspek analisis [16]. Oleh karena itu, penelitian ini dilakukan untuk menggabungkan analisis sentimen, toxicitas, dan emosi secara bersamaan pada teks forum menggunakan model *machine learning* berbasis bahasa Indonesia.

III. METODOLOGI PENELITIAN

A. Dataset

Dalam proses pelatihan model *machine learning*, penelitian ini memanfaatkan tiga dataset utama sebagai pendukung, yaitu dataset toxicity, dataset sentiment, dan dataset emotion.

	label	tweet
0	anger	Soal jln Jatibaru,polisi tdk bs GERTAK gubernu...
1	anger	Sesama cewe lho (kayaknya), harusnya bisa lebi...
2	happy	Kepingin gudeg mbarek Bu hj. Amad Foto dari go...
3	anger	Jln Jatibaru,bagian dari wilayah Tn Abang.Peng...
4	happy	Sharing pengalaman aja, kemarin jam 18.00 bata...

Gambar 3.1.1 Dataset Emotion

Dataset pertama yang digunakan adalah dataset emotion. Dataset ini memiliki total 4.300 data yang terdiri dari dua kolom utama, yaitu tweet dan label. Kolom tweet berisi komentar atau unggahan yang dibuat oleh netizen, sedangkan kolom label merepresentasikan kategori emosi yang terkandung dalam setiap komentar.

Dataset emotion ini mencakup lima kelas emosi, yaitu anger, happy, sadness, fear, dan love. Distribusi data pada masing-masing kelas adalah sebagai berikut: 1.100 data anger, 1.012 data happy, 996 data sadness, 645 data fear, dan 636 data love. Dengan adanya variasi kelas emosi tersebut, dataset ini digunakan untuk melatih model agar mampu mengenali dan mengklasifikasikan emosi yang terkandung dalam komentar netizen secara lebih akurat.

	kalimat	sentiment
0	Kalimat-kalimat tersebut adalah sebagai berikut	0
1	Manusia membutuhkan makanan dan air supaya men...	1
2	Tanaman hijau menggunakan air untuk membuat ma...	0
3	Tanaman yang tidak mendapat air akan layu dan ...	1
4	Keberhasilan belajar murid tidak hanya bergantung...	1

Gambar 3.1.2 Dataset Sentiment

Dataset kedua yang digunakan dalam penelitian ini adalah dataset sentiment. Dataset ini memiliki total 12.069 data yang tersusun dalam dua kolom utama, yaitu kalimat dan sentiment. Kolom kalimat berisi komentar atau opini yang disampaikan oleh netizen, serupa dengan dataset pada tahap sebelumnya. Sementara itu, kolom sentiment menunjukkan kategori sentimen dari setiap kalimat.

Kategori sentimen pada dataset ini dibagi menjadi tiga kelas, yaitu 0 (negatif), 1 (netral), dan 2 (positif). Distribusi data pada masing-masing kelas sentimen adalah 5.593 data negatif, 2.972 data netral, dan 2.582 data positif. Dataset ini digunakan untuk melatih model dalam mengklasifikasikan sentimen opini netizen ke dalam kategori negatif, netral, atau positif, sehingga model mampu memahami kecenderungan emosi dan sikap yang terkandung dalam teks secara lebih komprehensif.

	Tweet	HS	Abusive
0	- disaat semua cowok berusaha melacak perhatian...	1	1
1	RT USER: USER siapa yang telat ngasih tau elu?...	0	1
2	41. Kadang aku berfikir, kenapa aku tetap perc...	0	0
3	USER USER AKU ITU AKU\n\nKU TAU MATAMU SIPIT T...	0	0
4	USER USER Kaum cebong kاپir udah keliatan dong...	1	1

Gambar 3.1.3 Dataset Toxicity

Dataset ketiga yang digunakan dalam penelitian ini adalah dataset toxicity. Dataset ini memiliki total 13.169 data yang terdiri dari 13 kolom. Kolom-kolom tersebut pada dasarnya merepresentasikan berbagai indikator tingkat toksisitas dalam sebuah komentar. Namun, untuk mempermudah proses analisis serta meningkatkan

keterbacaan hasil, seluruh indikator tersebut kemudian disederhanakan menjadi dua kategori utama.

Kategori tersebut terdiri dari 0 (toxic) dan 1 (aman). Kategori toxic menunjukkan komentar yang mengandung unsur ujaran negatif atau berpotensi merugikan, sedangkan kategori aman merepresentasikan komentar yang tidak mengandung unsur toksisitas. Berdasarkan proses pengelompokan tersebut, diperoleh distribusi data sebanyak 7.522 data toxic dan 5.501 data aman. Dataset ini digunakan untuk melatih model dalam mendeteksi dan membedakan komentar yang bersifat toksik dan tidak toksik secara otomatis.

B. EDA (Exploratory Data Analysis)

Pengecekan Missing Values dan Data Duplikat

Pada tahap ini, dilakukan pengecekan kesehatan data (*data sanity check*) terhadap masing-masing dataset, yaitu Emotion, Sentiment, dan Toxicity. Proses ini bertujuan untuk memastikan bahwa data yang digunakan berada dalam kondisi yang layak sebelum masuk ke tahap pemodelan. Pengecekan difokuskan pada keberadaan *missing values* (NaN) dan data duplikat, karena kedua hal tersebut dapat memengaruhi kualitas pembelajaran model machine learning [17].

```
--- DIAGNOSA DATASET: Emotion ---
Ukuran Data: 4401 baris, 2 kolom
Aman: Tidak ada missing values.
PERINGATAN: Ada 11 data duplikat!
Kolom tersedia: ['label', 'tweet']
-----
```

Gambar 3.2.1 Diagnosa Dataset Emotion

Berdasarkan hasil pengecekan pada dataset Emotion, dataset memiliki total 4.401 baris dan 2 kolom. Tidak ditemukan adanya missing values, sehingga seluruh data dapat digunakan tanpa perlu dilakukan imputasi. Namun, terdeteksi sebanyak 11 data duplikat. Keberadaan data duplikat ini perlu diperhatikan karena dapat menyebabkan model mempelajari pola yang sama secara berulang, sehingga berpotensi menimbulkan bias pada proses pelatihan [18].

```
--- DIAGNOSA DATASET: Sentiment ---
Ukuran Data: 12609 baris, 2 kolom
Aman: Tidak ada missing values.
PERINGATAN: Ada 1516 data duplikat!
Kolom tersedia: ['kalimat', 'sentiment']
-----
```

Gambar 3.2.2 Diagnosa Dataset Sentiment

Pada dataset Sentiment, dataset terdiri dari 12.609 baris dan 2 kolom. Hasil pengecekan menunjukkan bahwa tidak terdapat missing values pada dataset ini. Meskipun demikian, jumlah data duplikat yang terdeteksi cukup signifikan, yaitu sebanyak 1.516 data. Jumlah duplikat yang relatif besar dapat memengaruhi distribusi data dan membuat model cenderung lebih dominan terhadap pola tertentu, sehingga perlu dilakukan penanganan lebih lanjut seperti penghapusan data duplikat [17].

```
--- DIAGNOSA DATASET: Toxicity ---
Ukuran Data: 13169 baris, 13 kolom
Aman: Tidak ada missing values.
PERINGATAN: Ada 125 data duplikat!
Kolom tersedia: ['Tweet', 'HS', 'Abusive', 'HS_Individual',
Moderate', 'HS_Strong']
-----
```

Gambar 3.2.3 Diagnosa Dataset Toxicity

Sementara itu, pada dataset Toxicity, dataset memiliki ukuran 13.169 baris dengan 13 kolom yang merepresentasikan berbagai kategori ujaran kebencian dan tingkat toksisitas. Hasil pengecekan menunjukkan bahwa dataset ini juga bebas dari missing values. Namun, ditemukan sebanyak 125 data duplikat. Walaupun jumlahnya tidak sebesar dataset Sentiment, keberadaan data duplikat tetap perlu diperhatikan agar hasil analisis dan performa model tetap akurat dan tidak bias [18].

Secara keseluruhan, hasil pengecekan menunjukkan bahwa ketiga dataset berada dalam kondisi yang cukup baik karena tidak ditemukan missing values. Namun, adanya data duplikat pada masing-masing dataset mengindikasikan perlunya tahap lanjutan berupa penghapusan duplikat agar data yang digunakan benar-benar bersih dan representatif. Tahap ini merupakan bagian penting dalam preprocessing karena kualitas data sangat berpengaruh terhadap performa akhir model machine learning [19].

Penghapusan Data Duplikat dan Missing Values

Setelah dilakukan pengecekan kondisi dataset, tahap selanjutnya adalah melakukan pembersihan lanjutan dengan menghapus data duplikat dan memastikan tidak adanya missing values pada seluruh dataset. Tahap ini bertujuan untuk meningkatkan kualitas data yang digunakan dalam proses pelatihan model, karena keberadaan data duplikat dapat menyebabkan bias serta memengaruhi distribusi data secara tidak proporsional [17].

```
Emotion: Duplikat dibuang. Sisa 4389 data.  
Sentiment: Duplikat dibuang. Sisa 11093 data.  
Toxicity: Duplikat dibuang. Sisa 13023 data.
```

Gambar 3.2.4 Data Duplikasi dibuang

Pada dataset Emotion, proses penghapusan duplikat dilakukan berdasarkan kolom teks (*tweet*). Setelah data duplikat dihapus, jumlah data yang tersisa menjadi 4.389 baris. Selain itu, dilakukan penyesuaian nama kolom dengan mengubah kolom *tweet* menjadi *text* agar struktur dataset lebih konsisten dan seragam dengan dataset lainnya. Konsistensi struktur data ini penting untuk mempermudah proses preprocessing dan pemodelan selanjutnya [10].


Selanjutnya, pada dataset Sentiment, data duplikat dihapus berdasarkan kolom *kalimat*. Setelah proses penghapusan, jumlah data yang tersisa adalah 11.093 baris. Sama seperti dataset Emotion, kolom *kalimat* juga diubah menjadi *text* dan kolom *sentiment* menjadi *label* untuk menyamakan format dataset. Langkah ini membantu menyederhanakan proses pengolahan data dan mengurangi potensi kesalahan saat pemanggilan kolom pada tahap analisis [18].

Pada dataset Toxicity, penghapusan duplikat dilakukan berdasarkan kolom *Tweet*. Setelah proses ini, jumlah data yang tersisa adalah 13.023 baris. Selain itu, kolom *Tweet* juga diubah menjadi *text* agar selaras dengan dataset lainnya. Dataset ini tidak memiliki missing values, sehingga tidak diperlukan proses imputasi atau penghapusan baris tambahan [17].

Secara keseluruhan, proses penghapusan data duplikat dan penyeragaman nama kolom menghasilkan dataset yang lebih bersih, konsisten, dan siap digunakan pada tahap preprocessing lanjutan dan pemodelan. Dengan menghilangkan data yang redundan, model diharapkan dapat mempelajari pola dari data yang benar-benar unik dan relevan, sehingga performa dan reliabilitas hasil klasifikasi dapat meningkat [10].

Visualisasi (EDA Chart)


Exploratory Data Analysis (EDA) dilakukan sebagai tahap awal untuk memahami karakteristik data sebelum proses pemodelan dilakukan. Tahapan ini bertujuan untuk mengidentifikasi distribusi kelas, potensi ketidakseimbangan data (*class imbalance*), serta implikasi awal terhadap pemilihan metode klasifikasi dan metrik evaluasi. Pada penelitian ini, EDA difokuskan pada visualisasi distribusi label pada tiga dataset yang digunakan, yaitu dataset emosi, dataset sentimen, dan dataset toksisitas (*hate speech*). Visualisasi distribusi kelas dilakukan menggunakan grafik batang (*count plot*) untuk memberikan gambaran kuantitatif mengenai jumlah data pada setiap kategori.



Gambar 3.2.5 EDA Chart Emotion


Hasil EDA pada dataset emosi menunjukkan bahwa terdapat lima kelas emosi, yaitu *anger*, *happy*, *sadness*, *fear*, dan *love*. Distribusi data relatif seimbang pada tiga kelas utama, yaitu *anger*, *happy*, dan *sadness*, yang masing-masing memiliki jumlah data di atas 900 sampel. Namun demikian, dua kelas lainnya, yaitu *fear* dan *love*, memiliki jumlah data yang lebih sedikit dibandingkan kelas lainnya. Ketidakseimbangan ini bersifat moderat dan

berpotensi menyebabkan model kurang optimal dalam mengenali emosi dengan frekuensi rendah. Oleh karena itu, hasil EDA ini menjadi dasar pertimbangan dalam pemilihan metrik evaluasi berbasis *macro-average* untuk menghindari bias terhadap kelas mayoritas.



Gambar 3.2.6 EDA Chart Sentiment

Pada dataset sentimen, distribusi label menunjukkan dominasi kelas sentimen negatif dibandingkan sentimen netral dan positif. Kelas negatif memiliki jumlah data yang paling besar, sementara dua kelas lainnya memiliki jumlah yang lebih kecil namun masih signifikan. Kondisi ini mengindikasikan adanya ketidakseimbangan kelas yang dapat memengaruhi performa model, khususnya jika hanya menggunakan metrik akurasi. Dalam konteks ini, EDA berperan penting dalam menegaskan perlunya evaluasi model menggunakan metrik yang lebih representatif, seperti *precision*, *recall*, dan *F1-score* pada masing-masing kelas, guna memperoleh gambaran performa yang lebih adil dan menyeluruh.




Gambar 3.2.7 EDA Chart Toxicity

Sementara itu, hasil EDA pada dataset toksisitas (hate speech) menunjukkan distribusi yang relatif lebih seimbang antara kelas non-hate dan hate dibandingkan dua dataset lainnya. Meskipun kelas non-hate masih sedikit lebih dominan, perbedaan jumlah data antar kelas tidak terlalu

ekstrem. Distribusi ini mencerminkan kondisi nyata pada media sosial, di mana sebagian besar konten tidak mengandung ujaran kebencian. Dengan distribusi yang relatif seimbang, dataset ini dinilai lebih stabil untuk proses pembelajaran model klasifikasi. Secara keseluruhan, hasil EDA memberikan landasan empiris yang kuat dalam menentukan strategi pemodelan, pemilihan algoritma, serta metode evaluasi yang digunakan pada tahap selanjutnya.

Analisis Distribusi Label Toxicity dan Penggabungan Label Toxicity

Analisis distribusi label toxicity dilakukan untuk memahami karakteristik data sebelum proses pemodelan, khususnya terkait keberadaan ujaran bermasalah dan tingkat ketidakseimbangan kelas. Pada dataset ini, anotasi toxicity direpresentasikan oleh dua label utama, yaitu Hate Speech (HS) dan Abusive, yang masing-masing menangkap bentuk perilaku toksik yang berbeda. Oleh karena itu, analisis awal difokuskan pada pengamatan komposisi data berdasarkan kombinasi kedua label tersebut guna memperoleh gambaran menyeluruh mengenai sebaran konten aman dan konten toksik.




Gambar 3.2.8 Pie Chart Komposisi Toxicity

Berdasarkan visualisasi detail komposisi data toxicity, dapat dilihat bahwa dataset memiliki sebaran kelas yang cukup beragam berdasarkan kombinasi label Hate Speech (HS) dan Abusive. Kategori bersih (clean), yaitu data yang

tidak mengandung HS maupun abusive, merupakan kelas dengan proporsi terbesar, yaitu sebesar 44,4% dari keseluruhan data. Hal ini menunjukkan bahwa sebagian besar konten dalam dataset masih tergolong aman dan tidak mengandung unsur toksisitas.

Di sisi lain, data yang tergolong toksik tersebar pada beberapa kategori. Data yang hanya mengandung Hate Speech (murni HS) memiliki proporsi sebesar 17,3%, sedangkan data yang hanya bersifat abusive (murni abusive) mencakup 13,4% dari total dataset. Selain itu, kategori HS + Abusive memiliki proporsi yang cukup signifikan, yaitu 25,0%, yang mengindikasikan adanya konten dengan tingkat toksisitas tinggi karena mengandung ujaran kebencian sekaligus bahasa kasar. Keberadaan kategori ini menegaskan bahwa sebagian besar konten toksik tidak berdiri sendiri, melainkan sering muncul dalam bentuk kombinasi karakteristik.

Secara keseluruhan, hasil ini menunjukkan bahwa meskipun data bersih masih mendominasi, porsi data toksik juga cukup besar dan tersebar dalam berbagai tingkat dan bentuk. Distribusi semacam ini mencerminkan kondisi nyata pada platform media sosial, di mana ujaran bermasalah tidak hanya muncul sebagai hate speech atau abusive secara terpisah, tetapi sering kali saling tumpang tindih. Oleh karena itu, pemahaman terhadap komposisi data ini menjadi dasar penting dalam menentukan strategi penggabungan label serta pendekatan pemodelan yang digunakan pada tahap selanjutnya



Gambar 3.2.9 Chart Distribusi Final

Berdasarkan visualisasi distribusi label akhir setelah proses penggabungan label, dataset terbagi ke dalam dua kelas utama, yaitu aman dan toxic. Kelas aman merepresentasikan data yang tidak mengandung unsur Hate Speech maupun abusive, sedangkan kelas toxic mencakup seluruh data yang memiliki salah satu atau kedua karakteristik tersebut. Hasil visualisasi menunjukkan bahwa jumlah data berlabel toxic sedikit lebih besar dibandingkan data berlabel aman, dengan masing-masing sebanyak 7.243 dan 5.780 sampel.

Meskipun kelas toxic lebih dominan, perbedaan jumlah data antar kelas tidak tergolong ekstrem sehingga tingkat ketidakseimbangan kelas dapat dikategorikan sebagai moderat. Distribusi ini mengindikasikan bahwa dataset masih berada pada kondisi yang relatif stabil untuk proses pelatihan model klasifikasi biner. Dengan komposisi kelas seperti ini, model memiliki peluang yang cukup seimbang untuk mempelajari pola pada kedua kelas tanpa bias berlebihan terhadap salah satu kelas tertentu.

Secara keseluruhan, distribusi label akhir ini mendukung tujuan pemodelan toxicity sebagai klasifikasi biner yang lebih sederhana dan terfokus. Penggabungan label menghasilkan representasi data yang lebih ringkas namun tetap mencakup seluruh variasi konten bermasalah, sehingga diharapkan dapat meningkatkan efektivitas pembelajaran model serta menghasilkan evaluasi performa yang lebih representatif pada tahap selanjutnya.

C. Pra-pemrosesan Data (Preprocessing)

Data Cleaning

Data cleaning merupakan bagian penting dalam tahap preprocessing teks karena kualitas data yang digunakan sangat menentukan performa model machine learning yang dibangun. Proses ini diawali dengan penerapan *case folding*, yaitu tahapan untuk menyeragamkan penggunaan huruf dengan mengonversi seluruh teks ke dalam bentuk huruf kecil (*lowercase*). Tujuan dari proses ini adalah untuk mengurangi variasi token yang sebenarnya tidak memiliki perbedaan makna, seperti perbedaan penulisan huruf kapital

pada kata yang sama. Tanpa *case folding*, kata-kata yang secara semantik identik dapat diperlakukan sebagai fitur yang berbeda oleh model, sehingga meningkatkan kompleksitas fitur dan tingkat *sparsity* pada representasi data teks. Dengan menerapkan *case folding*, jumlah fitur yang tidak perlu dapat ditekan, representasi data menjadi lebih konsisten, serta proses pembelajaran model menjadi lebih stabil dan memiliki kemampuan generalisasi yang lebih baik [1], [2].

Setelah proses *case folding* dilakukan, tahap selanjutnya adalah *text cleaning*, yang bertujuan untuk menghilangkan berbagai bentuk *noise* yang umum ditemukan pada data teks, khususnya data yang bersumber dari media sosial. Pada tahap ini, elemen-elemen yang tidak relevan terhadap tujuan analisis, seperti karakter khusus, tanda baca berlebihan, angka yang tidak bermakna, URL (*Uniform Resource Locator*), serta spasi ganda, dihapus dari teks. Proses *text cleaning* membantu menyederhanakan struktur teks sehingga informasi yang dipertahankan benar-benar merepresentasikan makna yang ingin dianalisis. Dengan struktur teks yang lebih bersih dan terstandarisasi, tahapan pemrosesan lanjutan seperti tokenisasi dan ekstraksi fitur dapat dilakukan dengan lebih efektif dan akurat [3].

Tahap preprocessing berikutnya adalah *stopword removal*, yaitu proses penghapusan kata-kata dengan frekuensi kemunculan tinggi namun memiliki nilai informasi yang rendah terhadap tujuan analisis. Pada penelitian ini, proses *stopword removal* dilakukan menggunakan daftar *stopword* bahasa Indonesia yang diperoleh melalui *StopWordRemoverFactory*, yang kemudian diperluas dengan penambahan *stopword* kustom. *Stopword* tambahan ini mencakup kata-kata tidak baku dan bersifat percakapan yang sering muncul pada teks informal, khususnya pada data media sosial. Pendekatan ini dilakukan untuk menyesuaikan proses preprocessing dengan karakteristik data yang digunakan, sehingga kata-kata yang tidak memberikan kontribusi semantik yang signifikan dapat dieliminasi secara lebih efektif dan model dapat lebih fokus pada kata-kata yang relevan dalam proses pembelajaran [1], [4].

Selanjutnya, proses preprocessing dilanjutkan dengan tahap *stemming* untuk menormalkan kata-kata ke bentuk dasarnya. Pada penelitian ini, *stemming* dilakukan menggunakan library Sastrawi, yang merupakan salah satu pustaka yang umum digunakan untuk pemrosesan teks berbahasa Indonesia. Sastrawi bekerja dengan menghilangkan imbuhan seperti awalan, akhiran, dan konfiks sesuai dengan kaidah morfologi bahasa Indonesia, sehingga kata-kata yang memiliki akar yang sama dapat direduksi ke bentuk dasar yang seragam. Penggunaan Sastrawi dipilih karena kemampuannya yang relatif stabil dan sesuai dengan karakteristik bahasa Indonesia dibandingkan metode *stemming* umum. Melalui proses ini, variasi kata akibat perbedaan imbuhan, seperti pada kata “membaca”, “dibaca”, dan “pembacaan”, dapat direduksi menjadi satu bentuk dasar, yaitu “baca”, sehingga jumlah fitur yang tidak perlu dapat dikurangi dan pola dalam data lebih mudah dikenali oleh model [2], [4].

Tahap akhir dari proses data cleaning adalah rekonstruksi teks, yaitu penggabungan kembali kata-kata yang telah melalui seluruh tahapan preprocessing menjadi satu kesatuan teks yang utuh. Setelah teks dibersihkan dari elemen yang tidak relevan, *stopword* dihapus, dan kata-kata dinormalisasi melalui *stemming*, teks yang dihasilkan menjadi lebih sederhana, terstruktur, dan representatif terhadap makna aslinya. Proses rekonstruksi ini penting agar data siap digunakan pada tahap selanjutnya, seperti ekstraksi fitur atau pemodelan machine learning. Kualitas data hasil preprocessing yang baik akan sangat berpengaruh terhadap performa model, baik dari segi akurasi maupun kemampuan generalisasi pada data yang belum pernah dilihat sebelumnya [3].

Cleaning Dataset

Setelah fungsi pembersihan teks (*bersihkan_teks*) dibuat, langkah berikutnya adalah menerapkan fungsi tersebut ke seluruh dataset yang digunakan dalam penelitian ini. Preprocessing dilakukan pada tiga dataset yang berbeda, yaitu dataset emosi, sentimen, dan toksisitas, agar setiap data teks memiliki format yang sama sebelum digunakan pada tahap selanjutnya [5]. Setiap teks pada kolom text

diproses menggunakan fungsi yang sama dan hasilnya disimpan pada kolom baru bernama `text_clean`, sehingga proses pengolahan data dapat dilakukan secara konsisten [6].

Penerapan preprocessing pada masing-masing dataset dilakukan secara terpisah untuk menjaga keaslian data sekaligus memudahkan proses analisis lanjutan [7]. Dengan adanya kolom `text_clean`, data teks asli tetap disimpan sehingga memungkinkan dilakukan perbandingan antara teks sebelum dan sesudah preprocessing [5]. Untuk memastikan bahwa proses pembersihan teks berjalan dengan baik, dilakukan pengecekan awal dengan menampilkan beberapa baris pertama dari dataset toksisitas, sehingga dapat dilihat secara langsung perbedaan antara teks mentah dan teks yang telah dibersihkan sebelum masuk ke tahap ekstraksi fitur dan pelatihan model [6].

Cleaning Dataset Selesai :

	text	text_clean
0	- disaat semua cowok berusaha melacak perhatian ...	- disaat semua cowok berusaha melacak perhatian ...
1	RT USER: USER siapa yang telat ngasih tau elu?...	siapa telat ngasih elu edan sarap gue bergaul ...
2	41. Kadang aku berfikir, kenapa aku tetap perc...	kadang aku berfikir aku tetap percaya tuhan pa...
3	USER USER AKU ITU AKU\N\NKU TAU MATAMU SIPIT T...	aku aku ku matamu sipit diliat mana aku
4	USER USER Kaum cebong kapir udah kelihatan dong...	kaum cebong kapir udah kelihatan dongaknya awal...

Gambar 3.3.1 Cleaning Dataset

Data Splitting

Pada tahap ini, data yang telah melalui proses preprocessing selanjutnya dibagi menjadi data latih (training set) dan data uji (testing set). Pembagian data dilakukan dengan rasio 80% untuk data latih dan 20% untuk data uji menggunakan metode *stratified split* agar distribusi label pada kedua subset tetap seimbang [7]. Pendekatan ini penting untuk memastikan bahwa model dilatih dan diuji pada data yang memiliki karakteristik kelas yang serupa.

Berdasarkan hasil pembagian data, dataset Emotion menghasilkan sebanyak 3.511 data latih dan 878 data uji. Jumlah tersebut dinilai cukup untuk melatih model dalam mempelajari pola emosi pada teks, sekaligus menyediakan data uji yang representatif untuk mengukur performa model terhadap data yang belum pernah dilihat sebelumnya [8].

Dengan adanya pemisahan ini, evaluasi model dapat dilakukan secara lebih objektif.

Selanjutnya, pada dataset Sentiment, diperoleh 8.861 data latih dan 2.216 data uji. Dataset ini memiliki jumlah data yang lebih besar dibandingkan dataset lainnya, sehingga diharapkan model dapat mempelajari variasi sentimen secara lebih baik dan stabil. Semakin banyak data latih yang digunakan, semakin besar pula peluang model untuk menghasilkan performa klasifikasi yang lebih konsisten [9].

Pada dataset Toxicity, proses data splitting menghasilkan 10.412 data latih dan 2.604 data uji. Pembagian ini dilakukan dengan tetap mempertahankan proporsi label untuk menghindari bias model terhadap kelas tertentu. Hal ini penting terutama pada tugas klasifikasi teks yang berpotensi memiliki ketidakseimbangan kelas, seperti deteksi ujaran toksik [7].

Secara keseluruhan, hasil pembagian data menunjukkan bahwa seluruh dataset telah siap digunakan pada tahap selanjutnya, yaitu ekstraksi fitur. Dengan pembagian data yang proporsional dan terkontrol, proses pelatihan dan evaluasi model diharapkan dapat menghasilkan performa yang lebih akurat dan dapat diandalkan [8].

```
--- Splitting Data ---
Emotion Split Berhasil!
- Training : 3511 baris
- Testing  : 878 baris
Sentiment Split Berhasil!
- Training : 8861 baris
- Testing  : 2216 baris
Toxicity Split Berhasil!
- Training : 10412 baris
- Testing  : 2604 baris

Semua data siap untuk ekstraksi fitur!
```

Gambar 3.3.2 data spitting

D. Ekstraksi Fitur dan Model

Berdasarkan proses ekstraksi fitur yang telah dilakukan, seluruh dataset berhasil diubah dari bentuk teks menjadi representasi numerik menggunakan metode TF-IDF. Hasil ini menunjukkan bahwa proses vektorisasi berjalan dengan

baik dan konsisten antara data latih dan data uji, di mana jumlah fitur yang digunakan dibatasi sebanyak 5.000 kata untuk setiap dataset [10]. Pembatasan ini bertujuan untuk menjaga keseimbangan antara kelengkapan informasi dan efisiensi komputasi.

Pada dataset Emotion, matriks TF-IDF yang dihasilkan memiliki ukuran 3.511×5.000 untuk data latih dan 878×5.000 untuk data uji. Ukuran matriks ini menunjukkan bahwa setiap data teks direpresentasikan oleh 5.000 fitur kata yang paling relevan berdasarkan bobot TF-IDF. Representasi ini memungkinkan model untuk menangkap karakteristik penting dari teks emosi tanpa harus memproses seluruh kosakata yang ada [12].

Selanjutnya, pada dataset Sentiment, hasil ekstraksi fitur menghasilkan matriks berukuran 8.861×5.000 untuk data latih dan 2.216×5.000 untuk data uji. Jumlah data yang relatif lebih besar pada dataset ini memberikan variasi konteks kata yang lebih luas, sehingga TF-IDF dapat memberikan bobot yang lebih informatif terhadap kata-kata yang memiliki peran penting dalam menentukan polaritas sentimen [10].

Pada dataset Toxicity, matriks TF-IDF yang dihasilkan berukuran 10.412×5.000 untuk data latih dan 2.604×5.000 untuk data uji. Hasil ini menunjukkan bahwa proses ekstraksi fitur berhasil dilakukan secara konsisten meskipun dataset memiliki jumlah data yang lebih besar dan karakteristik teks yang beragam. Representasi TF-IDF dinilai efektif untuk tugas klasifikasi teks karena mampu menonjolkan kata-kata yang sering muncul pada ujaran toksik namun jarang ditemukan pada teks lainnya [11].

Secara keseluruhan, hasil ekstraksi fitur menunjukkan bahwa seluruh dataset telah siap digunakan pada tahap pemodelan. Representasi numerik berbasis TF-IDF ini menjadi dasar bagi model machine learning seperti Naive Bayes dan Support Vector Machine dalam mempelajari pola dan melakukan proses klasifikasi secara lebih akurat [7].

```
--- Feature Extraction ---
Emotion TF-IDF Selesai!
- Ukuran Matrix Train: (3511, 5000)
- Ukuran Matrix Test : (878, 5000)
Sentiment TF-IDF Selesai!
- Ukuran Matrix Train: (8861, 5000)
- Ukuran Matrix Test : (2216, 5000)
Toxicity TF-IDF Selesai!
- Ukuran Matrix Train: (10412, 5000)
- Ukuran Matrix Test : (2604, 5000)
```

Gambar 3.3.3 Feature Extraction

E. Modeling

Training SVM sebelum Tuning

Model Support Vector Machine (SVM) dengan kernel linear dilatih pada tiga dataset yang berbeda, yaitu dataset emosi, sentimen, dan toksisitas, menggunakan representasi fitur berbasis TF-IDF. Hasil pengujian menunjukkan bahwa performa model bervariasi pada masing-masing dataset, yang mencerminkan perbedaan karakteristik data dan tingkat kompleksitas tugas klasifikasi. Pada dataset emosi, model SVM memperoleh akurasi sebesar 61,73%. Nilai ini menunjukkan bahwa model mampu menangkap pola umum dalam data, namun masih mengalami kesulitan dalam membedakan beberapa kelas emosi yang memiliki kemiripan semantik, seperti anger dan sadness atau fear dan love. Selain itu, keberadaan ketidakseimbangan kelas yang bersifat moderat pada dataset emosi turut memengaruhi kemampuan model dalam mengenali emosi dengan frekuensi kemunculan yang lebih rendah.

Pada dataset sentimen, model SVM mencapai akurasi sebesar 69,27%, yang lebih tinggi dibandingkan hasil pada dataset emosi. Peningkatan performa ini mengindikasikan bahwa tugas klasifikasi sentimen cenderung lebih sederhana dibandingkan klasifikasi emosi, karena jumlah kelas yang lebih sedikit dan perbedaan polaritas sentimen yang lebih jelas. Meskipun demikian, dominasi kelas sentimen negatif sebagaimana teridentifikasi pada tahap EDA berpotensi menyebabkan model lebih bias terhadap kelas mayoritas. Oleh karena itu, meskipun nilai akurasi tergolong cukup baik, hasil ini tetap perlu dievaluasi lebih lanjut menggunakan metrik lain seperti precision, recall, dan F1-score untuk memastikan bahwa performa model merata pada seluruh kelas.

Sementara itu, performa terbaik diperoleh pada dataset toksisitas dengan akurasi sebesar 87,67%. Hasil ini menunjukkan bahwa model SVM dengan kernel linear sangat efektif dalam membedakan teks yang mengandung ujaran kebencian dan teks non-hate. Distribusi kelas yang relatif lebih seimbang pada dataset toksisitas, sebagaimana ditunjukkan pada hasil EDA, menjadi salah satu faktor yang berkontribusi terhadap tingginya performa model. Selain itu, karakteristik ujaran kebencian yang cenderung memiliki pola leksikal yang lebih eksplisit membuat model lebih mudah mempelajari batas pemisah antar kelas. Secara keseluruhan, hasil ini mengindikasikan bahwa kombinasi TF-IDF dan SVM linear merupakan pendekatan yang cukup kuat untuk tugas deteksi toksisitas, sementara untuk tugas yang lebih kompleks seperti klasifikasi emosi, diperlukan strategi tambahan untuk meningkatkan performa model.

```
[SVM] Sedang melatih dataset: Emotion...
Training Emotion: 100% [100/100 [00:02<00:00, 47.64it/s]]
Selesai! Akurasi: 61.73%
[SVM] Sedang melatih dataset: Sentiment...
Training Sentiment: 100% [100/100 [00:02<00:00, 47.72it/s]]
Selesai! Akurasi: 69.27%
[SVM] Sedang melatih dataset: Toxicity...
Training Toxicity: 100% [100/100 [00:02<00:00, 47.80it/s]]
Selesai! Akurasi: 87.67%

Semua Model SVM Berhasil Dilatih!
```

Gambar 3.5.1 Training SVM sebelum Tuning

Komparasi Naive Bayes

Model Naive Bayes dengan varian Multinomial dilatih pada tiga dataset yang sama, yaitu dataset emosi, sentimen, dan toksisitas, menggunakan representasi fitur berbasis TF-IDF. Hasil pengujian menunjukkan bahwa performa model Naive Bayes bervariasi pada masing-masing dataset, dengan akurasi sebesar 58,88% pada dataset emosi, 63,22% pada dataset sentimen, dan 85,18% pada dataset toksisitas. Nilai akurasi yang lebih rendah pada dataset emosi dan sentimen mengindikasikan bahwa asumsi independensi antar fitur yang digunakan oleh Naive Bayes kurang sepenuhnya terpenuhi pada data teks dengan struktur semantik yang lebih kompleks. Khusus pada klasifikasi emosi, kemiripan konteks antar kelas emosi serta ketidakseimbangan distribusi data turut memengaruhi kemampuan model dalam membedakan kelas secara akurat.

Meskipun demikian, pada dataset toksisitas, model Naive Bayes menunjukkan performa yang relatif tinggi dengan akurasi di atas 85%. Hasil ini menunjukkan bahwa Naive Bayes masih efektif dalam mendeteksi pola leksikal yang khas pada ujaran kebencian, di mana keberadaan kata-kata tertentu memiliki kontribusi kuat terhadap penentuan kelas. Selain itu, distribusi kelas yang relatif lebih seimbang serta sifat ujaran kebencian yang cenderung eksplisit memudahkan model dalam melakukan klasifikasi. Secara keseluruhan, hasil ini menunjukkan bahwa Naive Bayes merupakan pendekatan baseline yang efisien dan cukup kompetitif untuk tugas deteksi toksisitas, namun memiliki keterbatasan dalam menangani tugas klasifikasi teks yang lebih kompleks seperti emosi dan sentimen, terutama ketika hubungan antar fitur memainkan peran yang signifikan.

```
[NB] Sedang melatih dataset: Emotion...
Training Emotion: 100% [100/100 [00:01<00:00, 93.10it/s]]
Selesai! Akurasi: 58.88%

[NB] Sedang melatih dataset: Sentiment...
Training Sentiment: 100% [100/100 [00:01<00:00, 93.82it/s]]
Selesai! Akurasi: 63.22%

[NB] Sedang melatih dataset: Toxicity...
Training Toxicity: 100% [100/100 [00:01<00:00, 92.44it/s]]
Selesai! Akurasi: 85.18%

Semua Model Naive Bayes Berhasil Dilatih!
```

Gambar 3.5.2 Komparasi Naive Bayes

Hyperparameter Tuning pada SVM

Untuk meningkatkan performa model, dilakukan pencarian parameter terbaik menggunakan GridSearchCV dengan validasi silang. Parameter yang diuji meliputi nilai C (regularisasi) dan jenis kernel (Linear vs RBF). Hasil tuning menunjukkan karakteristik yang berbeda untuk setiap dataset. Pada dataset Emosi, parameter terbaik adalah {'C': 1, 'kernel': 'linear'}, yang berarti model linear default sudah optimal sehingga akurasi tetap pada 61.7%. Namun, pada dataset Sentimen, parameter terbaik berubah menjadi {'C': 10, 'kernel': 'rbf'}, yang meningkatkan akurasi menjadi 69.7%. Peningkatan juga terjadi pada dataset Toxicity dengan parameter terbaik {'C': 1, 'kernel': 'rbf'}, di mana

akurasi naik menjadi 88.2%. Penggunaan kernel RBF terbukti membantu menangkap pola non-linear pada data sentimen dan toksisitas yang lebih kompleks.

Hyperparameter Tuning

```
=====
Sedang mengulik dataset: Emotion...
Fitting 3 folds for each of 4 candidates, totalling 12 fits
Setingan Terbaik Emotion: {'C': 1, 'gamma': 'scale', 'kernel': 'linear'}
Skor Validasi: 63.69%

=====
Sedang mengulik dataset: Sentiment...
Fitting 3 folds for each of 4 candidates, totalling 12 fits
Setingan Terbaik Sentiment: {'C': 10, 'gamma': 'scale', 'kernel': 'rbf'}
Skor Validasi: 67.28%

=====
Sedang mengulik dataset: Toxicity...
Fitting 3 folds for each of 4 candidates, totalling 12 fits
Setingan Terbaik Toxicity: {'C': 1, 'gamma': 'scale', 'kernel': 'rbf'}
Skor Validasi: 86.53%

=====
```

Gambar 3.5.3 Hyperparameter Tuning pada SVM

F. Evaluation

Analisis lebih mendalam dilakukan menggunakan Confusion Matrix pada model SVM terbaik. Pada analisis emosi, model mampu memprediksi kelas Anger dan Sadness dengan cukup baik, namun sering mengalami kesalahan klasifikasi (misclassification) antara Happy dan Love, serta Fear dan Sadness akibat kedekatan makna linguistik. Pada analisis sentimen, model memiliki nilai Recall yang sangat tinggi untuk kelas Negatif (0.87), namun performanya menurun pada kelas Positif dan Netral yang disebabkan oleh ketidakseimbangan data (imbalanced dataset). Sementara itu, pada analisis toksisitas, model menunjukkan performa yang sangat memuaskan dengan F1-Score rata-rata 0.88, membuktikan kemampuannya dalam membedakan komentar Toxic dan Aman dengan presisi tinggi.


[EMOTION DATASET]				
	precision	recall	f1-score	support
anger	0.62	0.76	0.68	220
fear	0.78	0.60	0.68	129
happy	0.57	0.51	0.54	203
love	0.77	0.70	0.73	127
sadness	0.50	0.53	0.52	199
accuracy			0.62	878
macro avg	0.65	0.62	0.63	878
weighted avg	0.63	0.62	0.62	878

[SENTIMENT DATASET]				
	precision	recall	f1-score	support
Negatif	0.72	0.87	0.78	1117
Positif	0.67	0.49	0.57	505
Netral	0.66	0.55	0.60	594
accuracy			0.70	2216
macro avg	0.68	0.64	0.65	2216
weighted avg	0.69	0.70	0.69	2216

[TOXICITY DATASET]				
	precision	recall	f1-score	support
Aman	0.87	0.87	0.87	1155
Toxic	0.89	0.89	0.89	1449
accuracy			0.88	2604
macro avg	0.88	0.88	0.88	2604
weighted avg	0.88	0.88	0.88	2604

Gambar 3.6.1 Evaluasi Model Terbaik

Pemetaan performa model dilakukan menggunakan Confusion Matrix untuk mengidentifikasi letak kesalahan prediksi secara spesifik. Warna biru pekat pada (Gambar 4.1.4 hingga 4.1.6) di ketiga grafik mengindikasikan bahwa model secara konsisten memprediksi kelas yang benar. Khusus pada model Toxicity, terlihat pemisahan yang sangat tegas antara kelas 'Aman' dan 'Toxic' dengan tingkat kesalahan (false positive/negative) yang sangat minim. Hal ini mengonfirmasi tingginya akurasi yang telah dicapai oleh model tersebut dibandingkan kategori lainnya.



Gambar 3.6.2 Confusion Matrix - Emotion

Gambar 4.1.1 Perbandingan SVM vs Naive Bayes

Berdasarkan hasil pengujian yang ditunjukkan pada Gambar Komparasi Algoritma (Sebelum Tuning), dapat dilihat bahwa algoritma SVM secara konsisten menghasilkan nilai akurasi yang lebih tinggi dibandingkan Naive Bayes pada seluruh dataset. Pada dataset emotion, SVM memperoleh akurasi sebesar 61,7%, sedangkan Naive Bayes mencapai 58,9%. Hasil ini menunjukkan bahwa SVM lebih efektif dalam menangkap pola emosi yang terdapat pada komentar netizen.


Pada dataset sentiment, SVM kembali menunjukkan performa yang lebih baik dengan akurasi sebesar 69,3%, dibandingkan Naive Bayes yang memperoleh akurasi 63,2%. Perbedaan ini mengindikasikan bahwa SVM memiliki kemampuan yang lebih baik dalam memisahkan kelas sentimen negatif, netral, dan positif.

Sementara itu, pada dataset toxicity, kedua algoritma menunjukkan performa yang cukup tinggi. Namun demikian, SVM tetap unggul dengan akurasi sebesar 87,7%, sedangkan Naive Bayes memperoleh akurasi 85,2%. Hal ini menunjukkan bahwa SVM lebih andal dalam mendeteksi komentar yang bersifat toksik dibandingkan Naive Bayes.


Secara keseluruhan, hasil komparasi sebelum dilakukan hyperparameter tuning menunjukkan bahwa SVM memiliki performa yang lebih stabil dan unggul dibandingkan Naive Bayes pada ketiga dataset. Oleh karena itu, SVM dipilih sebagai algoritma utama untuk dilakukan proses optimasi melalui hyperparameter tuning pada tahap selanjutnya.

B. Hyperparameter Tuning pada SVM

Hyperparameter tuning dilakukan untuk mengoptimalkan kinerja model Support Vector Machine (SVM) dengan cara mencari kombinasi parameter terbaik yang mampu meningkatkan performa klasifikasi. Pada penelitian ini, proses tuning diterapkan pada tiga dataset, yaitu emotion, sentiment, dan toxicity, dengan membandingkan nilai akurasi sebelum dan sesudah dilakukan tuning.



Gambar 3.6.3 Confusion Matrix - Sentiment





Gambar 3.6.4 Confusion Matrix - Toxicity

IV. RESULTS AND DISCUSSION

A. Perbandingan Model Baseline (SVM vs Naive Bayes)

Pada tahap awal eksperimen, kami melatih model SVM (dengan kernel Linear) dan Naive Bayes (Multinomial) menggunakan parameter default.





Gambar 4.2.1 Grafik Perbandingan Setelah Hyperparameter Tuning

Berdasarkan hasil pengujian pada test set yang ditunjukkan pada Gambar Peningkatan Akurasi Setelah Hyperparameter Tuning, terlihat bahwa proses tuning memberikan dampak positif terhadap performa model. Pada dataset emotion, nilai akurasi sebelum dan sesudah tuning tetap berada pada angka 61,7%, yang menunjukkan bahwa pengaturan parameter awal sudah cukup optimal sehingga proses tuning tidak memberikan peningkatan yang signifikan.

Pada dataset sentiment, terjadi peningkatan akurasi dari 69,3% sebelum tuning menjadi 69,7% setelah tuning. Meskipun peningkatan yang diperoleh relatif kecil, hasil ini menunjukkan bahwa penyesuaian hyperparameter mampu memberikan perbaikan terhadap kemampuan model dalam mengklasifikasikan sentimen netizen.

Sementara itu, peningkatan paling signifikan terlihat pada dataset toxicity. Akurasi model meningkat dari 87,7% sebelum tuning menjadi 88,2% setelah tuning. Hal ini mengindikasikan bahwa proses hyperparameter tuning berperan penting dalam meningkatkan kemampuan model SVM dalam mendeteksi komentar yang bersifat toksik dan tidak toksik.

Secara keseluruhan, hasil ini menunjukkan bahwa hyperparameter tuning pada SVM dapat meningkatkan performa model, meskipun besarnya peningkatan berbeda-beda pada setiap dataset. Perbedaan tersebut dipengaruhi oleh karakteristik data serta kompleksitas pola yang terdapat pada masing-masing dataset.

C. Evaluasi Detail Per Kategori

Evaluasi mendalam dilakukan terhadap performa model SVM terbaik dengan meninjau metrik statistik dan pola kesalahan prediksi. Berdasarkan hasil pengujian, model menunjukkan dominasi performa terbaik pada dataset Toxicity dengan rata-rata F1-Score mencapai 0,88. Tingginya skor ini mengonfirmasi bahwa model mampu membedakan komentar Toxic dan Aman dengan sangat presisi. Hal ini sejalan dengan visualisasi Confusion Matrix yang telah dipaparkan pada Bab III, di mana terlihat pemisahan yang sangat tegas pada diagonal utama untuk kategori toksisitas dengan tingkat kesalahan prediksi (false positive/negative) yang sangat minim.

Pada dataset Sentimen, model mencatat nilai Recall yang impresif sebesar 0,87 untuk kelas Negatif. Angka ini menunjukkan sensitivitas tinggi model dalam menangkap opini negatif yang mendominasi data. Namun, performa pada kelas Positif dan Netral cenderung lebih rendah, yang merupakan dampak langsung dari ketidakseimbangan proporsi data latih (class imbalance) di mana data negatif jauh lebih dominan dibandingkan kelas lainnya.

Terakhir, pada dataset Emosi, analisis terhadap pola kesalahan klasifikasi (misclassification) menunjukkan dinamika yang menarik. Meskipun model mampu mengenali kelas Anger dan Sadness dengan baik, terdapat kebingungan model dalam membedakan antara Happy dengan Love, serta Fear dengan Sadness. Fenomena ini dapat dimaklumi mengingat kedekatan makna linguistik dan konteks penggunaan kata antar-emosi tersebut yang sering tumpang tindih dalam percakapan media sosial sehari-hari.

D. Validasi Model dengan Data Baru (Model Validation)

Selain evaluasi berbasis metrik, dilakukan juga pengujian kualitatif dengan memasukkan kalimat baru yang belum pernah dilihat model sebelumnya. Pengujian ini bertujuan untuk mensimulasikan penggunaan model di dunia nyata. Berdasarkan hasil uji coba, model mampu mendeteksi konteks kalimat dengan tepat. Sebagai contoh, kalimat "Seneng banget akhirnya bisa lulus skripsi" berhasil

diklasifikasikan sebagai emosi Happy, sentimen Positif, dan Aman. Hal ini menunjukkan bahwa sistem pipeline yang dibangun sudah siap untuk diimplementasikan pada kasus penggunaan nyata.

```
Input: 'Jansen orang baik'
Hasil Prediksi Machine Learning
• Emosi : ANGER
• Sentimen : Positif
• Toksisitas : Aman
-----
Input: 'Seneng banget akhirnya bisa lulus skripsi tahun ini, makasih tuhan.'
Hasil Prediksi Machine Learning
• Emosi : HAPPY
• Sentimen : Positif
• Toksisitas : Aman
-----
Input: 'Hujan terus dari pagi, jadi batal main bola deh.'
Hasil Prediksi Machine Learning
• Emosi : HAPPY
• Sentimen : Negatif
• Toksisitas : Aman
-----
```

Gambar 4.4.1 Model Validation

V. CONCLUSION

Riset ini berhasil membuktikan bahwa cara pembelajaran mesin berbasis bahasa Indonesia bisa diterapkan dengan baik untuk mengelompokkan tulisan dari forum dalam banyak tugas, seperti melihat rasa, emosi, dan tanda-tanda ujaran kasar. Berdasarkan perbandingan dengan model dasar, Support Vector Machine (SVM) dengan tipe Linear selalu lebih baik daripada Naive Bayes di semua data, yang menandakan SVM lebih piawai mengurus ciri data tulisan forum yang kompleks, banyak fitur kosong, dan variasi kata yang beda jauh. Keunggulan ini paling kelihatan di data ujaran kasar yang berisi banyak kata makian dan bahasa santai.

Proses mengatur parameter terbaik dengan GridSearchCV sangat membantu membuat kinerja model jadi naik. Hasil coba-coba menunjukkan bahwa setiap data punya sifat yang lain, jadi butuh pengaturan parameter yang khusus. Di data emosi, model SVM dengan Linear dan pengaturan standar sudah memberi hasil paling bagus, yang artinya alur emosi cenderung lebih lurus dan sederhana. Sebaliknya, di data rasa dan ujaran kasar, memakai kernel RBF terbukti lebih jitu dalam menangkap pola yang tidak lurus, makanya nilai akurasi naik drastis. Penemuan ini menekankan betapa pentingnya menyetel parameter model sesuai tingkat kerumitan data yang dipakai.

Pengecekan lebih lanjut memakai matriks kebingungan dan ukuran klasifikasi menunjukkan performa model berbeda di tiap jenis tugas. Saat mengelompokkan emosi, model lumayan bisa mengenali marah dan sedih, tapi masih salah mengelompokkan emosi yang artinya berdekatan, seperti senang dan cinta, atau takut dan sedih. Dalam analisis rasa, model menunjukkan nilai ingat yang tinggi untuk kategori negatif, tetapi performanya turun di kategori positif dan netral karena data tidak terbagi rata. Sementara itu, dalam menemukan ujaran kasar, model SVM yang sudah disempurnakan meraih hasil terbaik dengan nilai F1-Score rata-rata 0,88 dan tingkat salah prediksi yang cukup rendah, memperlihatkan kemampuan kuat membedakan komentar aman dan kasar secara stabil.

Ujian tambahan pakai data baru yang belum pernah dilihat model sebelumnya memperkuat apa yang sudah ditemukan secara angka. Model bisa mengelompokkan maksud kalimat dengan benar di ketiga tugas sekaligus, yang berarti sistem yang dibuat punya kemampuan menyesuaikan diri yang baik dan mungkin bisa dipakai untuk keperluan sungguhan. Secara keseluruhan, hasil riset ini membuktikan bahwa SVM yang dipadukan dengan pengaturan parameter terbaik adalah cara yang ampuh untuk mengelompokkan tulisan forum bahasa Indonesia, terutama untuk tugas mencari ujaran kasar.

Walaupun begitu, penelitian ini masih punya kekurangan, terutama soal jumlah data yang tidak seimbang antar kelas dan kemiripan arti label emosi yang mempengaruhi ketepatan di beberapa kategori. Oleh karena itu, riset berikutnya disarankan untuk memasukkan metode deep learning yang mengandalkan pemahaman konteks, seperti LSTM atau BERT, serta menerapkan cara menyeimbangkan data agar model lebih peka terhadap kelas minoritas dan bisa mengerti konteks bahasa lebih dalam.

References

- [1] C. D. Manning, P. Raghavan, and H. Schütze, *Introduction to Information Retrieval*, Cambridge University Press, 2008.

- [2] Z. Waseem and D. Hovy, "Hate speech detection on social media," *Proceedings of the NAACL Student Research Workshop*, 2016.
- [3] B. Liu, *Sentiment Analysis and Opinion Mining*, Morgan & Claypool Publishers, 2012.
- [4] F. Alfina, R. Mulia, M. I. Fanany, and Y. Ekanata, "Hate speech detection in the Indonesian language," *Proceedings of ICACSYS*, 2017.
- [5] S. Mohammad, "Word affect intensities," *Proceedings of the ACL*, 2018.
- [6] A. McCallum and K. Nigam, "A comparison of event models for Naive Bayes text classification," *AAAI Workshop on Learning for Text Categorization*, 1998.
- [7] T. Joachims, "Text categorization with Support Vector Machines," *Proceedings of the European Conference on Machine Learning*, 1998.
- [8] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [9] G. Salton and C. Buckley, "Term-weighting approaches in automatic text retrieval," *Information Processing & Management*, vol. 24, no. 5, pp. 513–523, 1988.
- [10] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [11] D. Jurafsky and J. H. Martin, *Speech and Language Processing*, 3rd ed., draft version, 2023.
- [12] C. C. Aggarwal, *Machine Learning for Text*, Springer, 2018.
- [13] Sastrawi, "Sastrawi: Library for Indonesian Language Processing," 2016.
- [14] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer, 2006.
- [15] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.
- [16] L. M. Pratama, "Analisis Sentimen Berbasis Aspek dan Deteksi Emosi dari Media Sosial," *E-Journal UPR*, vol. 10, 2024.
- [17] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. Morgan Kaufmann, 2012.
- [18] I. H. Witten, E. Frank, and M. A. Hall, *Data Mining: Practical Machine Learning Tools and Techniques*, 3rd ed. Morgan Kaufmann, 2011.
- [19] P. Garcia-Laencina, J. L. Sancho-Gomez, and A. R. Figueiras-Vidal, "Pattern classification with missing data: a review," *Neural Computing and Applications*, vol. 19, no. 2, pp. 263–282, 2010.